

Modelo de clasificación para predicción de impago

Prueba técnica - Científico de datos



Oscar Carranza Jiménez - Mayo 2026

Objetivo del modelo

Construir un modelo de clasificación para estimar el riesgo de impago de créditos otorgados.

La variable objetivo: **ind_malo**

ind_malo = 0 indica que sí pagó

ind_malo = 1 indica que no pagó

Uso esperado del modelo:

Apoyar la toma de decisiones en la aprobación de créditos.

EDA

La cantidad de clientes que pagan es mayor que los que no lo hacen.


Se trata de un problema desbalanceado.

- 0 = 78 %
- 1 = 21 %

Se revisaron correlaciones numéricas con **ind_malo** y un heatmap para explorar relaciones entre variables.

EDA

A partir del heatmap se observan las correlaciones más fuertes



Las correlaciones ayudan a entender relaciones lineales iniciales. Aquí se muestran las 5 correlaciones mas fuertes

Preparación de datos

Del dataset original tenemos 12,660 créditos otorgados y en total hay 55 columnas.

Preparación de los datos:

- Sustitución de los valores nulos por la media de la variable
- Transformación de variables categóricas en variables booleanas
- Separación de train/test con estratificación

Modelos de entrenamiento

Modelo explicativo

Regresión logística balanceada:
Permite interpretar coeficientes y
entender la dirección del efecto de
las variables.

Modelo no explicativo

Captura relaciones no lineales e
interacciones entre variables, pero
es menos directo de interpretar.

Comparación de resultados

La siguiente tabla muestra las métricas de cada modelo

Modelo	Accuracy	Precision	Recall	F1	ROC AUC
Regresión logística sin balancear	0.79	0.48	0.08	0.14	0.69
Regresión logística balanceada	0.66	0.33	0.63	0.44	0.69
Random forest balanced	0.79	0.73	0.04	0.07	0.70

Comparación de resultados

Conclusión:

El accuracy no es suficiente para elegir el mejor modelo: los modelos con mayor accuracy casi no detectan impagos.

La regresión logística balanceada reduce el accuracy de 0.79 a 0.66, pero aumenta el recall de la clase de 0.08 a 0.63. Esto equivale a detectar 336 de 534 clientes que no pagaron, es decir, el 62.9% de los impagos reales.

Modelo seleccionado: regresión logística balanceada.

Estrategia propuesta

Usar la probabilidad de impago como un score de riesgo para apoyar decisiones de crédito.

- Riesgo bajo: aprobación normal
- Riesgo medio: revisión adicional o ajuste de condiciones
- Riesgo alto: solicitar más información, reducir monto aprobado o rechazar

El modelo no reemplaza la decisión final, pero ayuda a priorizar solicitudes según nivel de riesgo.

Conclusión

- El modelo seleccionado fue la regresión logística balanceada.
- Aunque tiene menor accuracy que otros modelos, detecta una mayor proporción de clientes con impago.
- El modelo puede apoyar decisiones de crédito mediante un score de riesgo, priorizando solicitudes que requieren revisión adicional.
- Siguiendo paso:
- Validar la estrategia en operación y monitorear su desempeño con métricas del modelo y del negocio.